Actividad 3 – Aprendizaje supervisado

Pruebas realizadas al componente desarrollado

Aura Cristina Restrepo Puentes

Corporación Universitaria Iberoamericana

Docente: Sandra Bautista

Ingeniería de Software

Inteligencia Artificial

Introducción

Como parte de la ampliación del proyecto de sistema inteligente de rutas, se incorporó un componente de aprendizaje supervisado orientado a calcular la duración estimada de los viajes. Para entrenar el modelo se requiere un conjunto de datos que relacione características del trayecto con su tiempo de recorrido. El trabajo previo utilizaba una representación académica simplificada de estaciones y el algoritmo A* para hallar rutas, pero carecía de registros históricos de duración. Por ello se diseñó un dataset sintético con fines exclusivamente académicos.

Fuente y naturaleza de los datos

El conjunto de datos fue generado mediante Python específicamente para esta actividad y se encuentra en la carpeta **datos/** bajo el nombre dataset_transporte.csv.

Se trata de datos sintéticos, sin relación con registros reales de TransMilenio ni con mediciones operativas. La muestra controlada permite entrenar y evaluar el modelo supervisado en un entorno académico.

Características del dataset

El dataset contiene **150 registros**, cada uno representando un escenario de viaje. Incluye cinco variables predictoras y una variable objetivo:

Variable	Tipo	Función
hora	Entero	Variable predictora
dia_semana	Entero	Variable predictora
pasajeros	Entero	Variable predictora
distancia_km	Decimal	Variable predictora
numero_paradas	Entero	Variable predictora
duracion_min	Decimal	Variable objetivo

Descripción de las variables

- **hora:** valor entre 0 y 23 que indica la hora del trayecto.
- **dia_semana:** número entre 0 y 6, donde 0 corresponde a lunes y 6 a domingo.
- **pasajeros:** cantidad estimada de usuarios en el viaje.
- **distancia_km:** longitud del recorrido en kilómetros.
- **numero_paradas:** número de paradas realizadas en el trayecto.
- **duracion_min:** tiempo estimado del viaje en minutos, usado como variable objetivo.

Generación de los datos

El dataset se construyó con el script datos/generar_dataset.py. Los registros se producen mediante valores aleatorios controlados para hora, día de la semana, número de pasajeros, distancia y paradas. La duración se calcula considerando:

- distancia recorrida,
- número de paradas,
- cantidad de pasajeros,
- factores asociados a la hora del día (ej. baja movilidad en la madrugada),
- factores ligados al día de la semana (ej. mayor tráfico los lunes),
- y una variabilidad aleatoria para simular escenarios diversos.

Uso de los datos en el aprendizaje supervisado

Las variables **hora, dia_semana, pasajeros, distancia_km y numero_paradas** se emplean como entradas (X), mientras que **duracion_min** es la variable objetivo (y).

El dataset se divide en entrenamiento (80%) y prueba (20%). Se utiliza un **DecisionTreeRegressor** de *scikit-learn* para predecir la duración de nuevos viajes.

Justificación del dataset

La construcción de este dataset responde a la necesidad de contar con información estructurada cuando no existen fuentes reales disponibles. Permite ejecutar el ciclo completo de aprendizaje supervisado: preparación, entrenamiento, predicción y evaluación. Los resultados son demostrativos y no deben interpretarse como tiempos reales de operación del transporte masivo.

Conclusión

El dataset sintético diseñado constituye una base controlada que facilita la incorporación del aprendizaje supervisado en el sistema inteligente de rutas. Su estructura permite relacionar características de los trayectos con la duración estimada, y a partir de ello entrenar un modelo de árbol de decisión capaz de realizar predicciones en escenarios nuevos.