Descripción del conjunto de datos para aprendizaje no supervisado

1. Nombre del conjunto de datos

Dataset de agrupamiento de viajes en el sistema de transporte.

2. Objetivo

Este conjunto de datos se emplea para diseñar y evaluar un modelo de aprendizaje automático no supervisado utilizando el algoritmo **K-Means**. La finalidad es identificar patrones y agrupar viajes con características semejantes, considerando variables como número de pasajeros, distancia recorrida, cantidad de paradas y duración estimada del trayecto.

3. Fuente de los datos

Dado que el proyecto académico no dispone de registros reales integrados al sistema, se generaron datos sintéticos mediante un script en Python.

Estos registros simulados se usan únicamente con fines académicos y para validar el funcionamiento del modelo, sin corresponder a información oficial del transporte público.

4. Características del conjunto de datos

El archivo empleado es datos/dataset_agrupamiento.csv, compuesto por **150 registros** y cuatro variables numéricas.

5. Preparación de los datos

El modelo toma las cuatro variables numéricas y aplica **StandardScaler** para estandarizarlas, lo que permite trabajar con escalas distintas de manera uniforme.

No se utilizan etiquetas previas de clasificación, ya que el entrenamiento es completamente no supervisado.

6. Algoritmo utilizado

Se implementó el algoritmo **K-Means** con tres grupos, empleando la biblioteca *scikit-learn* en Python. El procedimiento organiza los registros según la similitud de sus características numéricas.

7. Resultados generales

En la ejecución se analizaron **150 viajes**, obteniendo tres grupos. Las métricas fueron:

- **Inercia:** 117.57
- **Coeficiente de silueta:** 0.471

El valor de silueta refleja una separación moderada entre los grupos, lo que indica que existe margen de mejora en la calidad del agrupamiento.

8. Consideraciones y limitaciones

Los resultados dependen de los datos sintéticos y de la configuración del algoritmo. Por ello, no deben interpretarse como una representación del comportamiento real del transporte público.

Como trabajo futuro, se plantea incorporar datos reales y experimentar con diferentes cantidades de grupos para evaluar la calidad del modelo.

9. Archivo de resultados

El modelo produce el archivo datos/resultados_agrupamiento.csv, que contiene los registros analizados junto con el grupo asignado a cada uno.

Conclusión

El dataset sintético de agrupamiento constituye una base académica para aplicar aprendizaje no supervisado en el sistema de transporte. Su estructura permite explorar patrones de viaje y entrenar un modelo K-Means que, aunque limitado por la naturaleza simulada de los datos, ofrece una demostración clara del proceso de agrupamiento y abre la posibilidad de futuras mejoras con información real.